

線形回帰（１）

正田 備也

masada@rikkyo.ac.jp

統計モデルの3つの使い途

<https://www.stat.berkeley.edu/~aldous/157/Papers/shmueli.pdf>

Explanatory Model: ← e.g. 因果推論

test/quantify causal effect between constructs for “average” unit in population

Descriptive Model: ← e.g. 線形回帰における検定（今日の話題）

test/quantify distribution or correlation structure for measured “average” unit in population

Predictive Model: ← e.g. 深層学習

predict values for new/future individual units

統計モデルをdescriptive modelと
して使う

線形回帰モデルの場合。

線形回帰における検定

- 説明変数の目的変数に対する影響が有意か調べたい
- 帰無仮説：特定のcoefficientまたはinterceptがゼロ
- 上記の帰無仮説が棄却できるか？という検定
 - 今日の参考資料：大阪大学「計量経済基礎」（谷崎先生）の講義資料
 - http://www2.econ.osaka-u.ac.jp/~tanizaki/class/2018/basic_econome/02.pdf

モデルの仮定（単回帰の場合）

$$y_i = b + ax_i + u_i$$

1. x_i は固定された値をとると仮定
2. すべての*i*について、誤差項 u_i の期待値は0と仮定
3. すべての*i*について、誤差項 u_i の分散は σ^2 と仮定
4. すべての*i, j*について、誤差項 u_i と u_j が無相関（ $E[u_i u_j] = 0$ ）と仮定
5. すべての*i*について、誤差項 u_i は平均0、分散 σ^2 の正規分布に従うと仮定
6. $N \rightarrow \infty$ のとき、 $\sum_{i=1}^N (x_i - \bar{x})^2 \rightarrow \infty$ と仮定（ただし $\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$ ）

多変量正規分布では、無相関 \Leftrightarrow 独立

- 例えば下記Webページを参照

<https://mathtrain.jp/uncorrelated>

- 多変量正規分布では、無相関であることと、独立であることとは、同値
- よって、前のスライドの仮定から、誤差項 u_i は、すべて独立に、平均0、分散 σ^2 の正規分布に従うことが言える

補足：誤差項の正規性の仮定は必要か

- 検定をしたいなら、誤差が正規分布に従うという仮定は必要
- そうでないなら、不要
- 「線形回帰の仮定の誤解について」
 - <https://communities.sas.com/t5/Blog/%E7%B7%9A%E5%BD%A2%E5%9B%9E%E5%B8%B0%E3%81%AE%E4%BB%AE%E5%AE%9A%E3%81%AE%E8%AA%A4%E8%A7%A3%E3%81%AB%E3%81%A4%E3%81%84%E3%81%A6/ba-p/495164>

補足：回帰診断(regression diagnostic)

- statsmodels
 - https://www.statsmodels.org/dev/examples/notebooks/generated/regression_diagnostics.html

単回帰の正規方程式

- 以下の連立方程式を解けば、傾き a の最小二乗推定量 \hat{a} と、切片 b の最小二乗推定量 \hat{b} が求まる

$$\begin{bmatrix} \sum_{i=1}^N y_i \\ \sum_{i=1}^N x_i y_i \end{bmatrix} = \begin{bmatrix} N & \sum_{i=1}^N x_i \\ \sum_{i=1}^N x_i & \sum_{i=1}^N x_i^2 \end{bmatrix} \begin{bmatrix} \hat{b} \\ \hat{a} \end{bmatrix}$$

正規方程式を解くと...

\hat{a} も \hat{b} も、
正規分布に従う
独立な確率変数 u_i の
線形和になっている

$$\hat{a} = a + \sum_{i=1}^N \omega_i u_i$$

$$\hat{b} = b - (\hat{a} - a)\bar{x} + \frac{1}{N} \sum_{i=1}^N u_i$$

ただし、 \bar{x} は x_1, \dots, x_N の平均。 ω_i は下記のとおり。

$$\omega_i = \frac{(x_i - \bar{x})}{\sum_{j=1}^N (x_j - \bar{x})^2}$$

単回帰における検定(1/4)

- モデルの仮定より、以下のことが証明できる
 - 傾き a の最小二乗推定量 \hat{a} は不偏推定量、つまり $E(\hat{a}) = a$
 - \hat{a} の分散は、
$$V(\hat{a}) = \frac{\sigma^2}{\sum_{i=1}^N (x_i - \bar{x})^2}$$
 - 切片 b の最小二乗推定量 \hat{b} は不偏推定量、つまり $E(\hat{b}) = b$
 - \hat{b} の分散は、
$$V(\hat{b}) = \frac{\sigma^2 \sum_{i=1}^N x_i^2}{N \sum_{i=1}^N (x_i - \bar{x})^2}$$
 - \hat{a} と \hat{b} の共分散は、
$$\text{Cov}(\hat{a}, \hat{b}) = -\frac{\sigma^2 \sum_{i=1}^N \bar{x}}{\sum_{i=1}^N (x_i - \bar{x})^2}$$
- ここまでは、誤差の正規性の仮定は使っていない

単回帰における検定(2/4)

- \hat{a} も \hat{b} も、正規分布に従うことが示せる
 - 各 u_i は独立に正規分布に従う
 - \hat{a} も \hat{b} も、 u_i の線形和で表される
 - 正規分布にしたがう確率変数の和は、正規分布に従う
 - <http://joe.bayesnet.org/?p=4950>
- 以上のことから、 \hat{a} も \hat{b} も正規分布に従うことが言える

単回帰における検定(3/4)

- \hat{a} の分散の式も、 \hat{b} の分散の式も、未知の値 σ を含んでいる
 - どうする？
- 以下の s^2 が、誤差項の分散 σ^2 の不偏推定量となることが言える

$$s^2 = \frac{1}{N-2} \sum_{i=1}^N (y_i - \hat{b} - \hat{a}x_i)^2$$

- さらに $\frac{(N-2)s^2}{\sigma^2}$ が自由度 $N-2$ のカイ自乗分布に従うことも言える

t検定のもとになっている命題(1/3)

命題1

母集団が正規分布 $N(m, \sigma^2)$ に従うとき、

- その標本 X_1, \dots, X_N から求めた標本平均 \bar{X}_N と不偏標本分散 \bar{V}_N は、独立である。
- \bar{X}_N は、正規分布 $N(m, \frac{\sigma^2}{N})$ に従う。 ($\frac{\bar{X}_N - m}{\sigma} \sqrt{N}$ は $N(0,1)$ に従う。)
- $\frac{N-1}{\sigma^2} \bar{V}_N$ は、自由度 $N - 1$ のカイ二乗分布に従う。

t検定のもとになっている命題(2/3)

命題2

2つの確率変数 Z, Y が独立で、 Z が標準正規分布 $N(0,1)$ に従い、 Y が自由度 n のカイ二乗分布に従うならば、 $T \equiv \frac{Z}{\sqrt{Y/n}}$ は、自由度 n の t 分布に従う。

t検定のもとになっている命題(3/3)

系

母集団が正規分布 $N(m, \sigma^2)$ に従うとき、その標本 X_1, \dots, X_N から求めた標本平均 \bar{X}_N と不偏標本分散 \bar{V}_N とについて、 $(\bar{X}_N - m) \sqrt{\frac{N}{\bar{V}_N}}$ は自由度 $N - 1$ のt分布に従う。

- ポイント：標本から求めることのできる値（標本平均 \bar{X}_N と不偏標本分散 \bar{V}_N ）だけを使って、母集団の平均 m という未知の量に関する定量的な推定が可能になっている。

t検定の例

- 例：自由度20のt分布の両側5%点は2.0860

$$-2.0860 \leq (\bar{X}_N - m) \sqrt{\frac{N}{\bar{V}_N}} \leq 2.0860$$

- 帰無仮説が $m = 0$ のとき、 $\bar{X}_N \sqrt{\frac{N}{\bar{V}_N}} < -2.0860$ または $\bar{X}_N \sqrt{\frac{N}{\bar{V}_N}} > 2.0860$ ならば、有意水準5%において帰無仮説を棄却する。

単回帰における検定(4/4)

- 傾き a の最小二乗推定量 \hat{a} については、 $(\hat{a} - a)/s_{\hat{a}}$ が自由度 $N - 2$ の t 分布に従うことが言える。ただし

$$s_{\hat{a}} = \frac{s}{\sqrt{\sum_{i=1}^N (x_i - \bar{x})^2}}$$

- 切片 b の最小二乗推定量 \hat{b} については、 $(\hat{b} - b)/s_{\hat{b}}$ が自由度 $N - 2$ の t 分布に従うことが言える。ただし

$$s_{\hat{b}} = s \sqrt{\frac{\sum_{i=1}^N x_i^2}{N \sum_{i=1}^N (x_i - \bar{x})^2}}$$

単回帰における検定をどう行うか

- 単回帰における最小二乗推定量 \hat{a} と \hat{b} についても、以上の理屈により、t検定をおこなうことができる
- PythonならstatsmodelsのOLSを使えばよい
 - 実行結果に、ちゃんと検定統計量が表示される。

<https://www.statsmodels.org/stable/regression.html>

https://www.statsmodels.org/stable/generated/statsmodels.regression.linear_model.OLS.fit.html

統計モデルをpredictive modelとして使う

統計モデルを予測に使う（≡機械学習）

- 予測性能が良いのであれば、何が起きても構わない
 - 線形回帰の場合、いくつかの説明変数のp値が大きな値になろうが、予測性能が良いのであれば何の問題もない。
 - 多重共線性も問題にならない。
- モデルが正しいかどうか、問題にならない
- 特に深層学習の世界では、予測性能の向上だけ考える
 - モデルの解釈性の無さも問題にならない。


統計モデルをexplanatory modelと
して使う

統計モデルを説明に使う（≡因果推論）

「統計的因果効果推定の枠組みを通じて、得られたデータからまずは「ロバストな因果効果の推定」を行い、背後の共変量・交絡要因の影響を排除した「シンプルなメカニズムの理解」を行い”どのような介入が有効か”を示すことが解析実務では有用です。このような一連の解析はシステムに組み込まれていく汎用的機械学習モデルにはできない”データサイエンティストの腕の見せ所”になるのではないのでしょうか？」

（星野崇宏「統計的因果効果の基礎」『調査観察データの統計科学-因果推論・選択バイアス・データ融合-』85-86頁）

<https://gihyo.jp/dp/ebook/2019/978-4-297-11118-2>



<https://gihyo.jp/book/2021/978-4-297-12224-9>

